



UNIVERSIDAD NACIONAL DE ASUNCIÓN
FACULTAD DE
INGENIERÍA

Machine Learning 1

Clase 1: Fundamentos, Aplicaciones y Evaluación

Ingeniería Electrónica - 23433

Facultad de Ingeniería
Universidad Nacional de Asunción


20 de Julio de 2026



Diego Stalder
dstalder@ing.una.py



Carlos Benitez



Agenda del Día

- ¿Por qué Machine Learning ahora?
- IA vs ML vs DL
- Tipos de aprendizaje
- LLMs y Agentes
- Ética y datos
- Plan de evaluación
- Trabajos prácticos
- Proyecto final

Objetivo: Entender el *por qué*, el *para qué* y *cómo* empezar.

Para empezar...

Pregunta para la clase


¿Qué expectativas tienen sobre esta materia? ¿Qué les gustaría aprender?

Inicio de la computación



Alan Turing, 1951:

Parece probable que una vez que la máquina había comenzado el método de pensamiento, **no tardaría mucho en superar nuestros débiles poderes**. Podrían conversar con cada uno otros para agudizar su ingenio. Por lo tanto, en algún momento deberíamos esperar que las máquinas tomen el control ".



Frank Rosenblatt







Figure 1 ORGANIZATION OF THE MARK I PERCEPTRON

Perceptrón (1957, 1962): Descripción temprana y ingeniería de una sola capa y la red neuronal artificial multicapas





- Yann LeCun
- Geoffrey Hinton
- Yoshua Bengio

- "Los avances conceptuales en las Redes neuronales profundas"

Historia y Algunos Hitos



Robots on four wheels.




- 1943: Neural redes
- 1957-62: Perceptrón
- 1970-86: Retropropagación
RBM, RNN
- 1979-1998: CNN, MNIST,
LSTM, bidireccional RNN
- 2006: "Profundo
Aprendizaje", DBN
- 2009: ImageNet + AlexNet
- 2014: GAN
- 2016-17: AlphaGo,
AlphaZero
- 2017: 2017-19:

¿Por qué Machine Learning *ahora*?

El tsunami de datos

- 2.5 quintillones de bytes/día
- 95 % de los datos son de los últimos 5 años
- Fuentes: IoT, sensores, redes sociales, satélites



Dato impactante

En 2025, se generaron más datos que en toda la historia previa.

Evolución del cómputo

- GPUs: paralelización masiva
- TPUs: optimizadas para TensorFlow
- Nube elástica: AWS, GCP, Azure
- Costo: \$10/hora → \$0.001/hora (10 años)

Herramientas Open Source

Scikit-learn, PyTorch, TensorFlow, HuggingFace, LangChain

Evolución del cómputo

- GPUs: paralelización masiva
- TPUs: optimizadas para TensorFlow
- Nube elástica: AWS, GCP, Azure
- Costo: \$10/hora → \$0.001/hora (10 años)

Herramientas Open Source

Scikit-learn, PyTorch, TensorFlow, HuggingFace, LangChain

Industria y Negocios

- Finanzas: detección de fraudes
- Retail: recomendación de productos
- Manufactura: mantenimiento predictivo
- Logística: optimización de rutas

Ciencia y Salud

- Diagnóstico por imágenes médicas
- Descubrimiento de fármacos
- Genómica computacional

Pregunta para la clase

¿En qué productos o servicios han visto aplicaciones de ML?

Algunas cosas que hice y hago



Algunas cosas que hice y hago


Reconstructions of 12-Lead ECGs using LSTMs




Señales ECG




Demanda de Energía en Paraguay



Niveles de Ríos



Time series for dengue epidemic modelling in Paraguay and Peru



Calidad del Aire

Se cuenta con una red de monitoreo de material particulado (MP) desde el año 2019. Se encuentran en funcionamiento 11 estaciones autónomas en la ciudad de Asunción.





Figure 2: Web Application Main Page: Current AQI values, 6 and 12 hour forecasts and health recommendations.




phpMyAdmin

Mostrando filas 0 - 24 (total de 442700, La consulta tardó 0.0004 segundos.) [ID: 442719... - 442695...]


Perfilando [Editar en línea] [Editar] [Explicar SQL] [Crear código PHP] [Actualizar]

ID	FECHA	HORA	MP1	MP2_5	MP10	TEMPERATURA	HUMEDAD	PRESION	BATERIA
442719	04-08-2023	12:10	2.849	3.579	32.969	35.4	35.0	1001.9	88
442718	04-08-2023	12:05	2.970	3.939	6.679	35.3	34.9	1002.0	88
442717	04-08-2023	12:00	7.929	8.840	9.189	35.3	34.2	1002.1	87
442716	04-08-2023	11:55	2.500	3.509	3.789	35.5	34.5	1002.3	87
442715	04-08-2023	11:50	2.240	3.519	10.309	35.2	36.3	1002.3	87
442714	04-08-2023	11:45	2.679	3.289	3.989	34.8	36.2	1002.4	87
442713	04-08-2023	11:40	2.490	3.159	3.509	35.0	36.6	1002.5	87

Dispositivo de medición inteligente para la caracterización demanda del consume eléctrico



Diseño final de la placa en vista superior



Diseño final de la placa en vista inferior



Dispositivo de medición para la caracterización de los perfiles de consumo energético desarrollado en el 2023



H. R. E. M. Fernandez, "Monitoreo y Caracterización de los Perfiles de Demanda Horaria de Energía Eléctrica de Usuarios de la ANDE," Tesis de grado, Facultad de Ingeniería, Universidad Nacional de Asunción, Asunción, Paraguay, 2023.

Análisis de los datos con métodos de clustering y reducción de dimensionalidad





Imagen referencial de la metodología aplicada

5


Conjunto de datos





Serie temporal correspondiente a uno de los clientes

- Este estudio utilizó un conjunto de datos proporcionado por la ANDE.
- Los mismos fueron obtenidos durante un programa piloto de medición en el año 2021.
- El mismo incluye registros horarios de consumo eléctrico de 121 hogares.


Análisis de datos



Interpretación de los clústeres obtenidos



Clústeres 0, 3, 5, 8, 9 y 10: agrupan un número significativo de series (entre 10 y 17) que presentan una periodicidad diaria marcada. Este comportamiento indica hábitos regulares de uso eléctrico, lo que sugiere perfiles de consumidores con rutinas estables. Las formas de los medoides capturan claramente estos ritmos.



Diego Galeano

Can we predict unknown side effects using the sparse data from clinical trials?



Prof. Alberto Paccanaro

Cell Reports
Methods



Colegas, Diego, and Alberto Paccanaro, "Machine learning prediction of side effects for drugs in clinical

Distributed Systems Lab



Prof Derlis Gregor



Prof Mario Arzamendia




UNIVERSIDAD NACIONAL
DE ASUNCIÓN
FACULTAD DE
INGENIERÍA



UNIVERSIDAD
LOYOLA
ANDALUCÍA



Intelligent Transportation Systems



Precision Agriculture



Autonomous Surface Vehicle

FUNDACIÓN ETEA
PARA EL DESARROLLO Y LA COOPERACIÓN

fundación
ayesa





2015

Goodfeilow et at.




2018


Karras, Laine,Aila.



2020


MIT Intro to Deep Learning







	Claude 3.5 Sonnet	Claude 3 Opus	GPT-4o	Gemini 1.5 Pro	Llama-400b (early snapshot)
Graduate level reasoning <i>GPQA, Diamond</i>	59.4%* 0-shot CoT	50.4% 0-shot CoT	53.6% 0-shot CoT	—	—
Undergraduate level knowledge <i>MMLU</i>	88.7%** 5-shot	86.8% 5-shot	—	85.9% 5-shot	86.1% 5-shot
	88.3% 0-shot CoT	85.7% 0-shot CoT	88.7% 0-shot CoT	—	—
Code <i>HumanEval</i>	92.0% 0-shot	84.9% 0-shot	90.2% 0-shot	84.1% 0-shot	84.1% 0-shot
Multilingual math <i>MGSM</i>	91.6% 0-shot CoT	90.7% 0-shot CoT	90.5% 0-shot CoT	87.5% 8-shot	—
Reasoning over text <i>DROP, F1 score</i>	87.1 3-shot	83.1 3-shot	83.4 3-shot	74.9 Variable shots	83.5 3-shot Pre-trained model
Mixed evaluations <i>BIG-Bench-Hard</i>	93.1% 3-shot CoT	86.8% 3-shot CoT	—	89.2% 3-shot CoT	85.3% 3-shot CoT Pre-trained model
Math problem-solving <i>MATH</i>	71.1% 0-shot CoT	60.1% 0-shot CoT	76.6% 0-shot CoT	67.7% 4-shot	57.8% 4-shot CoT
Grade school math <i>GSM8K</i>	96.4% 0-shot CoT	95.0% 0-shot CoT	—	90.8% 11-shot	94.1% 8-shot CoT

* Claude 3.5 Sonnet scores 67.2% on 5-shot CoT GPQA with maj@32
** Claude 3.5 Sonnet scores 90.4% on MMLU with 5-shot CoT prompting






Machine Learning




Deep Learning





[ResearchGate Ramesh Eluri](#) R.V.R. & J.C. College of Engineering


La arquitectura Transformer (2017) revolucionó la IA al permitir el procesamiento paralelo masivo y la atención contextual en terabytes de texto.



Propósito General vs Propósito Específico



Taxonomias




Definición Formal de Machine Learning

Tom Mitchell (1997)

*“Un programa de computadora **aprende** de la experiencia **E** con respecto a una tarea **T** y una medida de rendimiento **P**, si su rendimiento en **T**, medido por **P**, mejora con **E**.”*

Ejemplo: Clasificación de señales ECG

- **T**: Clasificar señales como normales o anormales
- **P**: Precisión (Accuracy)
- **E**: 10,000 registros etiquetados por cardiólogos



Pregunta para la clase

¿Pueden identificar T, P y E en un problema de su interés?

Los Tres Grandes Tipos de Aprendizaje

Tipo	Definición	Ejemplo en Ingeniería
Supervisado	Datos etiquetados (x, y)	Clasificación de fallas
No Supervisado	Datos sin etiquetas x	Agrupamiento de patrones
Refuerzo	Agente + Entorno + Recompensa	Control de robot



Aprendizaje Supervisado



Aprendizaje No Supervisado




Aprendizaje Por Refuerzo

Los Tres Grandes Tipos de Aprendizaje


Formulación General

- **Supervisado:** $\{(x_i, y_i)\}_{i=1}^N$, minimizar $\sum L(y_i, f(x_i)) + \lambda \Omega(f)$
- **No Supervisado:** $\{x_i\}_{i=1}^N$, encontrar estructura $g : X \rightarrow Z$
- **Refuerzo:** Maximizar $\sum \gamma^t R(s_t, a_t)$



Aprendizaje Supervizado: Regresión Lineal vs. Clasificación Logística

Regresión Lineal (Continua)




$$y = w^T x + b$$

Costo (MSE): Minimizar el Error Cuadrático Medio.



Uso Ingenieril: Predecir la vida útil restante de un componente en función del voltaje.

Regresión Logística (Binaria)




$$P(y = 1|x) = \text{sigmoide}(w^T x + b)$$

Costo (Cross-Entropy): Medir la divergencia probabilística.

Uso Ingenieril: Clasificar si un componente electrónico es Defectuoso o Aprobado.




K-Means (No Supervisado)




- **Objetivo:** Minimizar la inercia intra-cluster.
- **Concepto:** Encontrar centroides óptimos para agrupar datos no etiquetados espacialmente.




Dimensionality Reduction is the process of reducing the number of input variables (features) in a dataset while preserving as much important information as possible.



Q-Learning (Por Refuerzo)



- **Mecanismo:** Maximizar recompensas futuras mediante la Ecuación de Bellman (factor de descuento gamma).
- **Concepto:** Ciclo iterativo de aprendizaje por prueba y error continuo.




Quiz Rápido

¿Qué tipo de aprendizaje usarían para recomendar productos a clientes?

- (A) Supervisado
- (B) No Supervisado
- (C) Refuerzo

La Responsabilidad del Ingeniero: El Problema del Outlier



Casos Extremos donde los modelos fallan catastróficamente:



Condiciones climáticas atípicas cegando sensores ópticos.



Peatones con trayectorias irregulares frente a vehículos autónomos.



Sesgos algorítmicos propagados por datos de entrenamiento desbalanceados.

NotebookLM

Supervisado: Regresión Lineal

Modelo:

$$\hat{y} = w^T x + b$$

Función de costo (MSE):

$$J(w, b) = \frac{1}{2N} \sum_{i=1}^N (y_i - \hat{y}_i)^2$$

Solución analítica:

$$\hat{w} = (X^T X)^{-1} X^T y$$

Aplicación

Predecir vida útil de componentes electrónicos en función de temperatura y voltaje.

Quiz Rápido

¿Qué problema tiene la solución analítica cuando $X^T X$ no es invertible?

Pregunta para la clase

¿Cuándo creen que la regresión lineal NO sería adecuada?


No Supervisado: K-Means Clustering

Objetivo: Minimizar la inercia intra-cluster

$$J = \sum_{k=1}^K \sum_{i \in C_k} \|x_i - \mu_k\|^2$$

Algoritmo:

1. Inicializar K centroides μ_k aleatoriamente
2. Asignar cada punto al centroide más cercano
3. Recalcular centroides como media del cluster
4. Repetir pasos 2-3 hasta convergencia



El problema del K

¿Cómo elegir K ? Método del codo, coeficiente de silueta.

Aplicación

Segmentación de clientes eléctricos por patrón de consumo horario.

Quiz Rápido

¿Qué sucede si elegimos $K=1$? ¿Y si $K=n$ (número de muestras)?

Problema Seq2Seq

• Translation

Input :

"genetic
algorithm"

output :

"基因演算法"

• Chat-bot

Input :

"Hello"

output :

"Hello"

• Speech recognition

Input :



output :

"基因演算法"

• Image caption

Input :



output :

"A boy ride on a bike"

- BERT ([Google](#))
- XLNet ([Google / CMU](#))
- RoBERTa ([Facebook](#))
- DistilBERT ([HuggingFace](#))
- CTRL ([Fuerza de ventas](#))
- GPT-2 ([OpenAI](#))
- ALBERT ([Google](#))
- Megatron ([NVIDIA](#))


 [sebastianruder](#) / [NLP-progress](#)

NLP-progress

Repository to track the progress in Natural Language Processing (NLP), including the datasets and the current state-of-the-art for the most common NLP tasks.

Los datos de entrenamiento de ChatGPT

- Mientras **más grandes son los modelos**, estos requieren **más cantidad de datos**
- **Los datos influyen** fuertemente los **temas** sobre los que ChatGPT responde a las personas
 - Poemas, código, guiones de **películas**
- ChatGPT es pre-entrenado con **páginas web y libros**:
 - Wikipedia (~20GB)
 - BookCorpus (~5GB)
 - [Common Crawl](#) (>20TB)
 - [C4](#) (~350GB, 15M paginas)
 - [The Pile](#) (800GB)
 - etc.



C4 dataset

“El conjunto de datos estuvo dominado por sitios **web de industrias** que incluyen **periodismo, entretenimiento, desarrollo de software, medicina y creación de contenido**, lo que ayuda a explicar por qué estos campos pueden verse amenazados por la nueva ola de inteligencia artificial.”

RANK	DOMAIN	CATEGORY	PERCENT OF ALL TOKENS
1	patents.google.com	Law & Government	0.46%
2	wikipedia.org	News & Media	0.19%
3	scribd.com	News & Media	0.07%
4	nytimes.com	News & Media	0.06%
5	journals.plos.org	Science & Health	0.06%
6	latimes.com	News & Media	0.05%
7	theguardian.com	News & Media	0.05%
8	forbes.com	News & Media	0.05%
9	huffpost.com	News & Media	0.04%
10	patents.com	Law & Government	0.04%
11	washingtonpost.com	News & Media	0.03%
12	coursera.org	Jobs & Education	0.03%
13	fool.com	Business & Industrial	0.03%
14	frontiersin.org	Science & Health	0.03%
15	instructables.com	Technology	0.03%

Fuente: [Inside the secret list of websites that make AI like ChatGPT sound smart](#). *The Washington Post*


Pregunta para la clase

¿Qué implicaciones tiene que los datos provengan principalmente de sitios en inglés y de países desarrollados?

Lenguaje Natural

Exámenes diseñados para los seres humanos

- Estos exámenes permiten certificarse en la vida real o medir habilidades en áreas muy diversas
- Temas como **leyes, biología, lenguaje, matemática, historia, programación**
- Las notas se comparan con las de otras personas que también forman parte del



LLMs: El Nuevo Paradigma en IA


¿Qué son los LLMs?

- Modelos de lenguaje de gran escala
- Entrenados en terabytes de texto
- Arquitectura: Transformer (2017)
- Ejemplos: GPT-4, Gemini, Llama 3, Claude

Problemas críticos:


- **Sesgo algorítmico:**
 - COMPAS (recidivismo racial)
 - Amazon (sesgo de género en contratación)
 - Reconocimiento facial (menor precisión en personas de color)
- **Privacidad:** datos sensibles expuestos, re-identificación
- **Responsabilidad:** ¿quién responde por fallos?
- **Desinformación:** DeepFakes, noticias falsas
- **Impacto laboral:** automatización de empleos
- **Derechos de autor:** uso de contenido sin licencia

Un modelo es tan ético, justo y neutral como los datos históricos con los que fue entrenado.




Justicia (COMPAS)

Falsos positivos desproporcionados en la predicción de reincidencia debido a sesgos raciales históricos en los datos de arrestos.



Recursos Humanos (Amazon)

Sistema automatizado de currículums que penalizaba a candidatas femeninas por haber sido entrenado con contrataciones históricas dominadas por hombres.



Reconocimiento Facial

Tasas de error drásticamente superiores en mujeres y personas de piel oscura frente a hombres blancos.

Quiz Rápido

¿Quién es responsable si un modelo de IA causa daño? ¿El desarrollador, la empresa, el usuario?

Plan de Evaluación

Componente	Frecuencia	Ponderación
Cuestionarios	Según cronograma	10 %
TPs prácticos	TP1–TP6	10 %
Primer Examen Parcial	Cuestionario + TP práctico	30 %
Segundo Examen Parcial	GitHub Page	20 %
Proyecto de Curso	Desarrollo, presentación y defensa	30 %
TOTAL		100 %

Nota importante

Todos los componentes son obligatorios. Nota mínima de aprobación: **60/100**.

Trabajos Prácticos (TPs)

TP	Descripción
TP1	Mi primer repositorio en GitHub
TP2	Comparación de modelos de regresión lineal y no lineal + regularización
TP3	Ejemplo de clusterización con SVM
TP4	Ejemplo de comparación de similitud de imágenes con PCA
TP5	Optuna con comparación de modelos de decisión
TP6	GitHub Pages para el proyecto final

Fechas clave

- TP1: Semanas 1–2
- TP2: Semanas 3–6
- TP3–TP5: Semanas 9–13
- TP6: Semanas 14–15

Cuestionarios

Cuestionario	Semanas	Temas
C1	1–2	Introducción, tipos de ML, ética
C2	3–6	Preprocesamiento, regresión, regularización
C3	9–10	SVM, kernel trick
C4	11	PCA, LDA, t-SNE
C6	12–13	Árboles de decisión, ensambles

Modalidad

Cuestionarios teórico-prácticos en el aula virtual.

Plan de Evaluación

Componente	Frecuencia	Ponderación
Cuestionarios	Según cronograma	10 %
TPs prácticos	TP1–TP6	10 %
Primer Examen Parcial	Cuestionario + TP práctico	30 %
Segundo Examen Parcial	GitHub Page	20 %
Proyecto de Curso	Desarrollo, presentación y defensa	30 %
TOTAL		100 %

Nota importante

Todos los componentes son obligatorios. Nota mínima de aprobación: **60/100**.

Proyecto de Curso (30 %)

Desafío

1. Elegir un desafío
2. Identificar el tipo de problema
3. Seleccionar y aplicar métodos de solución
4. Documentar todo el pipeline
5. Presentar y defender el proyecto

Requisitos mínimos

- Repositorio GitHub con código y documentación
- GitHub Pages con la presentación del proyecto
- Notebook de Jupyter con el análisis completo
- Comparación de al menos 3 modelos
- Evaluación con métricas apropiadas

Cronograma de Evaluaciones

Semanas	Cuestionario	Trabajo Práctico
1–2	C1	TP1: Mi primer repo de GitHub
3–6	C2	TP2: Comparación de modelos de regresión
7–8	C3	Receso por evaluaciones
9–10		TP3: Clusterización con SVM
11		TP4: Comparación de similitud de imágenes con PCA
12–13	C6	TP5: Optuna con comparación de modelos de decisión
14–15	Tutoría de proyecto	

Recursos y Referencias

-  Mitchell, T. M. (1997). *Machine Learning*. McGraw-Hill.
-  Géron, A. (2022). *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow*. O'Reilly.
-  Müller, A. C., & Guido, S. (2016). *Introduction to Machine Learning with Python*. O'Reilly.
-  Hastie, T., et al. (2009). *The Elements of Statistical Learning*. Springer.
-  Sutton, R. S., & Barto, A. G. (2018). *Reinforcement Learning: An Introduction*. MIT Press.