

Machine Learning 1

(código: 23433)

Universidad Nacional de Asunción

Facultad de Ingeniería

Semestre Séptimo - Electrónica

Horarios de Clase

Clases Teóricas

Día: **Lunes**

Contenido: Fundamentos matemáticos, demostraciones de algoritmos y discusión conceptual.

Docente: Dr. Diego Stalder

Clases Prácticas


Día: **Lunes**

Contenido: Programación en Python, uso de librerías y aplicaciones sobre datasets reales.

Docente: Ing. Carlos Benitez

Periodo: Del 20 de julio al 2 de noviembre de 2026 (14 semanas efectivas).

Plan de Evaluación y Exoneración



Condiciones para Exonerar

- Completar el **100%** de los TPs y Cuestionarios.
- Haber presentado satisfactoriamente el proyecto final (defensa, informe y GitHub Page).

Puntajes de Exoneración

≥ 81 **puntos:** Exoneración con Calificación 4

≥ 91 **puntos:** Exoneración con Calificación 5


Cuestionarios y Trabajos Prácticos

Semanas	Cuestionario	Trabajo Práctico
1-2	Cuestionario 1	TP1: Primer repo de GitHub para todos los TPs.
3-6	Cuestionario 2	TP2: Comparación de modelos de regresión y regularización.
<i>Semanas 7-8: Receso por evaluations</i>		
9-10	Cuestionario 3	TP3: Ejemplo de clusterización con SVM.
11	Cuestionario 4	TP4: Comparación de similitud de imágenes con PCA.
12-13	Cuestionario 6	TP5: Optuna con comparación de modelos de decisión.
14-15	Tutoría de proyecto	TP6: GitHub Pages para el proyecto final.

Introducción a Machine Learning

Tradicionalmente, en la programación, le pedimos a un experto humano que escriba reglas lógicas (una función f) para resolver un problema.


En Machine Learning, invertimos el paradigma: tratamos al modelo como una **"caja negra"** (Black Box). Introducimos datos ($\mathcal{D}$), y un algoritmo *aprende* a configurar los parámetros de esa caja para producir la salida correcta.



Ejemplo clásico (Andrew Ng): Predicción de precios de vivienda en Portland. Si alimentamos nuestra "caja" con el área de las casas y el número de dormitorios como **features**, la caja aprenderá a predecir o estimar el precio de venta (**target**) de una casa nueva que nunca ha visto.

Categorías de Machine Learning

Las tareas en aprendizaje automático se dividen fundamentalmente según el tipo de datos y la retroalimentación del entorno:



Categorías de Machine Learning


Según el tipo de aprendizaje:

- **Supervised Learning:** El modelo aprende con datos etiquetados (entradas con salidas conocidas).
- **Unsupervised Learning:** Los datos no tienen etiquetas. Busca estimar la estructura natural.

Según la naturaleza del problema:

- **Clasificación:** Salidas con valor discreto (categorías).
- **Regresión:** Salidas con valor continuo.

Chart 2 | Classification vs. Regression



Unsupervised Learning



Source: Towards Data Science, Supervised vs. Unsupervised Learning

Algunos Modelos Centrales de Machine Learning 1

I. Regresión & GAM

Modelando relaciones entre variables.

Regresión Lineal: Ajusta una función lineal a los datos. Es muy interpretable (ej. CAPM).


Ridge y Lasso: Mejoran la predicción manejando alta correlación mediante regularización.

Observación: GAM (Generalized Additive Models)

Suma de funciones no lineales que predice relaciones complejas sin perder interpretabilidad:

$$g(E(Y)) = \beta_0 + f_1(X_1) + f_2(X_2) + \cdots + f_p(X_p)$$

Chart 3 | Linear Regression vs. GAM: Fitting a Straight Line vs. a More Flexible Function



II. Árboles de Decisión


Ensamblajes: Bagging y Boosting con Figuras Visuales

Árbol de Decisión: Segmenta características. Es visual pero inestable por sí solo.

Random Forest (Bagging): Ensambla múltiples árboles descorrelacionados para mayor precisión.


XGBoost (Boosting): Árboles secuenciales que aprenden de errores anteriores. Muy robusto.

Chart 4 | Tree-Based Model Example



Source: Analytics Vidhya, Tree Based Algorithms

Chart 5 | Bagging



Source: Analytics Vidhya

III. Clustering (Agrupamiento)

Encontrando grupos naturales.


El **Clustering** agrupa datos sin etiquetar basándose en sus similitudes.

K-Means: El algoritmo más común. Asigna cada punto al centroide (k) más cercano minimizando las distancias.

Formalismo Matemático (Inercia):

$$\arg \min_S \sum_{i=1}^k \sum_{\mathbf{x} \in S_i} \|\mathbf{x} - \boldsymbol{\mu}_i\|^2$$

Chart 6 | K-Means Clustering



Source: Introduction to K-means Clustering, Dileka Madushan

IV. Reducción de Dimensionalidad (PCA y SVD)

Simplificando la complejidad matemática.

PCA: Combina variables en componentes principales independientes. Reduce la redundancia conservando la varianza.


SVD (Singular Value Decomposition)

La factorización matricial fundamental de la que deriva PCA:

$$X = U\Sigma V^T$$


Donde U son los vectores singulares izquierdos, Σ la matriz diagonal de valores singulares, y V^T los vectores singulares derechos ortogonales.

Chart 7 | PCA Example: Bring Three-Dimension Problem to Two Dimensions with Transformation



Source: Principal Component Analysis, Victor Powell

Chart 8 | Deep Learning: Mimic Human Brains



Source: The difference between artificial and biological neural networks, Richard Nagyfi

V y VI. Deep Learning & NLP

Formas más avanzadas de Inteligencia Artificial.

Deep Learning (DL)

Redes neuronales artificiales (ANN) con múltiples capas complejas para procesar información imitando el cerebro. Procesan datos en secuencias y mejoran enormemente la precisión de predicción, aunque son una "caja negra".

Natural Language Processing (NLP)


Analiza grandes cantidades de texto para extraer *insights*. En el sector financiero se usa para detectar el tono en reportes o impacto de noticias.

Nota Importante: Machine Learning 2

Estos temas avanzados, incluyendo arquitecturas profundas y procesamiento de lenguaje natural, serán objeto de estudio exhaustivo en la asignatura de **Machine Learning 2**.

Ecosistema del Machine Learning

Chart 1



Source: Cambridge Finsights

Table 1

Machine Learning Models

Variables	ML Algorithm Type	
	Supervised (Target Variable)	Unsupervised (No Target Variable)
Continuous	Regression - Linear; Penalized Regression/LSSO - Logistic - Classification and Regression Tree (CART) - Random Forest	Dimensionality Reduction - Principal Components Analysis (PCA) Clustering - K-Means - Hierarchical
	Categorical - Logit - Support Vector Machine (SVM) - K-Nearest Neighbor (KNN) - Classification and Regression Tree (CART)	Dimensionality Reduction - Principal Components Analysis (PCA) Clustering - K-Means - Hierarchical
Continuous or Categorical	Neural Networks Deep Learning Reinforcement Learning	Neural Networks Deep Learning Reinforcement Learning

Source: Kathleen DeRose, CFA and Christophe Le Lannou. "Quantitative Methods, Machine Learning", CFA Institute, 2019.

¿Por qué usamos Python?

Python se ha consolidado como el lenguaje estándar absoluto en la industria e investigación de Inteligencia Artificial.

- **Sintaxis legible y minimalista:** Permite centrarse en la matemática y la lógica, no en los pormenores del lenguaje.
- **Ecosistema insuperable:** Acceso a bibliotecas robustas para cálculo científico y procesamiento de datos.
- **Comunidad y soporte global.**

NumPy

Pandas

Matplotlib

Scikit-Learn

PyTorch

TensorFlow

Jupyter

Próximos Pasos (TP1)

Preparando tu entorno de trabajo profesional

Por favor, dirígete al [README de la Clase 1](#) para completar lo siguiente:

- **Instalación de Conda:** Gestor de entornos base.
- **Creación de un Entorno Virtual:** Aislamiento de dependencias.
- **Uso de Poetry:** Manejo robusto de dependencias de Python.
- **Integración de Jupyter Notebooks:** Para experimentación interactiva.
- **Repositorio en GitHub:** Creación y vinculación de tu primer repo.