

Machine Learning 1

Clase 2: Fuentes de Datos, Datasets Clásicos y Repositorios para Proyectos

Universidad Nacional de Asunción

Facultad de Ingeniería

Semestre Séptimo - Electrónica

¿Por Qué el Dato es Lo Más Importante?

"Garbage In, Garbage Out" (GIGO)

En Machine Learning, un algoritmo es tan bueno como los datos con los que fue entrenado. Un modelo simple con excelentes datos superará siempre a una red neuronal compleja alimentada con datos defectuosos.

Criterios de Calidad

- **Representatividad:** Debe reflejar la realidad del entorno operal.
- **Granularidad:** Precisión temporal o resolución espacial adecuada.
- **Compleitud:** Mínima presencia de valores vacíos o nulos.

Riesgos y Sesgos (Bias)

- **Sesgo de Muestreo:** Entrenar con sub-representación de clases.
- **Ruido y Anomalías:** Sensores descalibrados en hardware.
- **Fugas de Información:** Contaminar test con datos de entrenamiento.

Realidad del Pipeline en Ingeniería ML


En el ámbito laboral y de investigación en ingeniería, la mayor parte del esfuerzo humano se dedica al tratamiento preliminar:

El 70% del Trabajo es Dataset

- Búsqueda y descarga en repositorios.
- Análisis Exploratorio de Datos (**EDA**).
- Limpieza de outliers y valores nulos.
- Normalización y Feature Engineering.

Hoy conoceremos exactamente dónde buscar estos datos en alta calidad para sus proyectos de semestre.

Tiempo invertido en el Pipeline de ML



Datasets Clásicos de Estudio (Tabulares)


Para prototipar y validar ideas de algoritmos de manera directa, usamos estándares que ya vienen integrados en librerías como `scikit-learn`:

Iris Dataset (Clasificación)

El "Hello World" de Machine Learning. Clasifica 3 especies de flores a partir de 4 medidas físicas (largo/ancho del pétalo y sépalo).

California & Boston Housing (Regresión)

Predicción del valor económico de viviendas en base a variables como cercanía a centros productivos, impuestos y zonas geográficas.



Datasets Clásicos - Visión y Catálogos Generalistas

Dataset MNIST

El referente universal para introducirse en **Redes Neuronales y Visión por Computador**.

- **Contenido:** 70,000 imágenes en blanco y negro de dígitos manuscritos.
- **Formato:** Matrices de 28×28 píxeles en escala de grises.
- **Objetivo:** Reconocimiento óptico de caracteres (OCR).

UCI Machine Learning Repository

El mayor archivo universitario del mundo para docencia e investigación en ciencia de datos.

- **Respaldo Académico:** Desarrollado y mantenido por la Universidad de California (Irvine).
- **Diversidad:** Cientos de tablas gratuitas sobre acústica, sensores médicos, mecánica y energía.
- **Ventaja:** Datos perfectamente documentados y abiertos.

[UCI Repository](#) ↗

Repositorios de Visión Artificial (Computer Vision)

Para entrenar sistemas modernos capaces de reconocer objetos de forma autónoma (YOLO, Faster R-CNN, TensorFlow Lite):

Roboflow Universe


La mayor comunidad colaborativa de visión en el mundo. Más de **200,000 datasets pre-annotados** con bounding boxes y máscaras de segmentación listos para descargar.

MS COCO & ImageNet

Los estándares monumentales en deep learning industrial, conteniendo millones de imágenes cotidianas e industriales etiquetadas al detalle.

[Roboflow ↗](#)

[MS COCO ↗](#)



Aplicaciones de Visión Artificial en Electrónica

Utilizar catálogos abiertos de visión nos permite desarrollar prototipos de hardware y software de alto impacto ingenieril:

Control de Calidad PCB

Inspección óptica automática con cámaras por encima de cintas transportadoras para identificar **soldaduras frías**, **cortos eléctricos** o **componentes faltantes** en placas de circuito impreso.

Robótica Autónoma

Navegación visual en drones e integrados automotrices autónomos (ROS) para el reconocimiento y evasión de obstáculos, personas o lectura de señales.

Telemedición Smart Grid

Lectura automática de números LED o mecánicos mediante cámaras web embebidas en medidores eléctricos convencionales, evitando el reemplazo masivo de contadores.

Repositorios de Datos Climáticos y Ambientales

Las series temporales atmosféricas son inestimables para proyectar consumo en redes y generación solar o eólica:

Copernicus ECMWF (ERA5)


Servicio de la Agencia Espacial Europea que entrega reanálisis atmosféricos globales históricos **hora por hora** por latitud y longitud planetaria (viento, temperatura, radiación).

NOAA & NASA Earth Data

Catálogos federales norteamericanos con radares precipitacionales, oceanografía y mediciones de ozono y temperaturas globales.

[Copernicus ↗](#)

[NOAA Data ↗](#)



Ingesta Climática en Python: Open-Meteo API

¿Por qué la recomendamos para el Proyecto?

Open-Meteo ofrece consultas HTTP gratuitas e inmediatas a archivos meteorológicos históricos en cualquier coordenada geográfica **sin necesidad de API Keys ni registros**.

Ejemplo elemental de obtención automática de datos para **Asunción, Paraguay** (Lat: -25.26, Lon: -57.57):

```
import requests
import pandas as pd

# Consultar temperatura y lluvia diaria histórica de Asunción via HTTP REST API
url = "https://archive-api.open-meteo.com/v1/archive?latitude=-25.26&longitude=-57.57&start_date=2023-01-01&end_da
datos = requests.get(url).json()

# Convertir instantáneamente a un DataFrame de Pandas
df_clima = pd.DataFrame(datos['daily'])
df_clima['time'] = pd.to_datetime(df_clima['time'])
print(df_clima.head()) # Listo para graficar o correlacionar
```

Repositorios Demográficos y Socio-Económicos

Útiles al evaluar viabilidad de proyectos, consumo por habitante o proyecciones de conectividad en redes sanitarias y eléctricas:

World Bank Open Data

El Banco Mundial publica miles de indicadores anuales para todos los países sobre infraestructura, adopción de internet, electrificación rural y deuda soberana.

[World Bank ↗](#)

IPUMS & Gapminder

- **IPUMS International:** El líder mundial en provisión de microdatos censales de hogares e individuos desidentificados.
- **Gapminder Open Data:** Series socioeconómicas longitudinales extremadamente limpias para visualizaciones dinámicas del desarrollo.

[IPUMS ↗](#)

[Gapminder ↗](#)

Biomedicina y Electrónica Médica (Healthcare ML)


Para la especialidad de Electrónica Médica, el aprendizaje automático es el motor en sistemas hospitalarios modernos de monitoreo no invasivo:

PhysioNet (MIMIC-III / MIMIC-IV)

El estándar cumbre creado por el **MIT & Beth Israel Hospital**. Contiene millones de registros clínicos reales y desidentificados de pacientes de cuidados intensivos (UCI).

- Señales **ECG y EEG en crudo**.
- Presión arterial continua e invasiva.
- Laboratorios horarios para predecir sepsis o fallos cardíacos en sala.

[PhysioNet MIT ↗](#)



Diagnóstico Médico y Radiografía Asistida

El diagnóstico por visión artificial permite realizar cribados hospitalarios automáticos de altísima precisión y bajo costo operacional:

NIH Chest X-ray Dataset

Publicado por los Institutos Nacionales de Salud del gobierno norteamericano (NIH).

- **Volumen:** Más de 100,000 radiografías torácicas anonimizadas.
- **Etiquetado:** Clasificadas por médicos en 14 anomalías y patologías pulmonares de gravedad (neumonía, cardiomegalia, efusión pleural, masas).

COVID-19 Radiography Database

Repositorio especializado disponible públicamente en Kaggle y portales clínicos.

- **Contenido:** Placas radiográficas divididas en COVID-19 positivo, pulmón normal, neumonías virales no relacionadas y opacidades torácicas.
- **Ideal para:** Redes Convolucionales (CNN) de clasificación médica rápida en servicios de urgencias.

Datos de Paraguay – Sector Eléctrico (ANDE)


Para desarrollar proyectos de ingeniería que resuelvan necesidades inmediatas dentro del territorio nacional paraguayo:

Curva de Demanda en el SIN

El Sistema Interconectado Nacional (SIN) gestionado por **ANDE, Itaipú y Yacyretá** muestra patrones periódicos con dos picos críticos diarios:

- **Pico Siesta (14:00 hs):** Impulsado masivamente por aire acondicionado doméstico y carga comercial.
- **Pico Noche (20:30 hs):** Carga residencial y alumbrado.

Predecir con exactitud esta curva a 24/48 hs vista usando ML es un clásico de ingeniería de redes eléctricas.



Datos de Paraguay - INE, Salud e Hidrología

INE & datos.gov.py

El **Instituto Nacional de Estadística (INE)** provee microdatos descargables en CSV de la **Encuesta Permanente de Hogares (EPHC)** y del Censo 2022. Ideales para segmentación y consumo urbano en Paraguay.

Epidemiología (MSPBS)

La Dirección de Vigilancia de la Salud publica reportes históricos de **Arbovirosis (Dengue, Chikungunya, Zika)** por municipios. Excelente para modelar propagación de brotes vs lluvias.

Meteorología (DMH)

La Dirección de Meteorología e Hidrología (DINAC) almacena alturas fluviométricas de los ríos **Paraguay y Paraná** para predecir crecidas fluviales y alertas tempranas de estiaje.

Caso de Estudio Aplicado (Paso 1): Definición del Problema

Título del Mini-Proyecto:

"Predicción Horaria de Demanda Eléctrica en el Sistema Interconectado Nacional (SIN) según Variables Climáticas de Asunción"

Objetivo de Ingeniería

Construir un modelo supervisado que ayude al despachador de red (ANDE) a pronosticar con anticipación si la demanda excederá el límite crítico en verano ante olas de calor.

Unión de Repositorios

- **Dataset A (Target Y):** Registro horario de demanda activa de la red SIN (ANDE / Sector Eléctrico de Paraguay).
- **Dataset B (Features X):** Historial de temperaturas diarias y radiación solar en Asunción obtenidas vía **Open-Meteo API**.

Caso de Estudio (Paso 2): Exploración y Correlación (EDA)


Al unir las dos bases por hora cronológica (timestamp), grafiquemos el comportamiento físico del sistema en el Paraguay:

Descubrimiento Clave en el EDA

Comportamiento No Lineal: Cuando la temperatura exterior es inferior a los 26°C, la carga base es relativamente estable.

El Efecto Aire Acondicionado: A partir de los 28°C - 30°C, la curva se dispara exponencialmente por encendidos simultáneos del parque de climatización en Gran Asunción.

Una simple regresión lineal fallaría aquí; el EDA nos sugiere un modelo polinómico o Random Forest.



Caso de Estudio (Paso 3): Pipeline en nuestro Notebook

Así luce nuestro archivo notebooks/01_EDA.ipynb al importar la tabla consolidada en Python:

```
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns

# 1. Cargar el dataset combinado en crudo que guardamos en nuestra carpeta de trabajo
df_sin = pd.read_csv("data/raw/demanda_sin_clima_py.csv")

# 2. Verificar la integridad: no queremos valores nulos en medio de la serie temporal
print("Anomalías vacías encontradas por variable:\n", df_sin.isnull().sum())
df_clean = df_sin.dropna().copy()

# 3. Resumen estadístico de las temperaturas y cargas horarias
display(df_clean.describe())

# 4. Graficar la relación (Regresión Cuadrática de Prueba) en Seaborn
plt.figure(figsize=(7, 3.2))
sns.regplot(data=df_clean, x="temp_ambiente", y="demanda_mw", order=2,
            scatter_kws={'alpha':0.6, 'color':'#D97706'}, line_kws={'color':'#1E3A8A', 'linewidth':2})
plt.title("Ajuste del Modelo de Regresión Cuadrático: Demanda vs Temperatura")
plt.xlabel("Temperatura Ambiente (°C)"); plt.ylabel("Demanda Activa SIN (MW)")
plt.grid(True, alpha=0.3); plt.show()
```

Próximos Pasos para tu Grupo de Trabajo

Lista de Verificación para el TP / Proyecto:

- **1. Exploración en Equipo:** Revisa los repositorios mostrados hoy (Roboflow Universe, Open-Meteo, PhysioNet o INE/ANDE Paraguay) y definan su tema.
- **2. Descarga a Carpeta Raíz:** Descarga la base original e inyectala *sin alterar* en el directorio de su repositorio de GitHub: data/raw/.
- **3. Cuidado con el Gitignore:** Si tu tabla o carpeta de imágenes excede los 50 MB, recuerda agregarlo al archivo .gitignore para evitar bloqueos al realizar push a GitHub.
- **4. Inicialización Práctica:** Ejecuta exitosamente la primera carga con pandas `.read_csv()` dentro de su notebook inicial: notebooks/01_EDA.ipynb.

¡Recuerden aprovechar el horario de tutorías con el auxiliar o el docente para validar sus ideas de proyecto!