

Machine Learning 1

Clase 4: Preprocesamiento

Ingenieria Electronica - 23433

Diego Stalder
Carlos Benitez
dstalder@ing.una.py

Facultad de Ingenieria
Universidad Nacional de Asuncion

10 de Agosto de 2026

- **CNMAC 2024:** Caso de Estudio
- **Datos Actuales:** Nueva Muestra (2024-2025)
- Carga y Concatenacion
- **EDA:** Analisis Exploratorio
- Datos Faltantes y Duplicados
- **Feature Engineering**
- Normalizacion y Codificacion
- **Preparacion para Modelos**
- **Resultados:** Visualizaciones Clave

Objetivo

Del paper a la practica:

Preprocesar datos academicos para predecir rendimiento

Preprocesar es el 80 % del trabajo

Articulo: Modelling Academic Performance: A Case Study on Engineering Courses

- **Autores:** Hans Mersch, Carlos Sauer, Jose Rivas, Diego Stalder
- **Evento:** CNMAC 2024 (Congreso Nacional de Matematica Aplicada y Computacional)
- **Datos:** 2012-2019 (190,108 matriculaciones)
- **Objetivo:** Predecir aprobacion/reprobacion de estudiantes

Variables Clave del Estudio

Variable	Descripcion
Curso	Nombre de la asignatura (461 clases)
Carrera	7 carreras de Ingenieria
1P, 2P	Notas del primer y segundo parcial
2nd Try	Si ya cursó y reprobó antes
L/W	Notas de laboratorio/taller
Final	Aprobado/Reprobado

Resultados del CNMAC 2024

Modelos Utilizados

- **Regresion Logistica:** Baseline interpretable
- **MLP (Red Neuronal):** 5 capas (10-20-10-10-2)
- **Optimizacion:** Adam (Kingma et al., 2014)
- **Metrica:** MCC (Matthews Correlation Coefficient)

Resultados Comparativos

Modelo	Accuracy	MCC
Regresion Logistica	85.8 %	0.726
MLP (5 capas)	88.3 %	0.771

Variables Mas Importantes (Modelo 5)

- **2nd Try:** Coeficiente 6.59 (mas predictivo)
- **1P:** Coeficiente 1.98 (deteccion temprana)

El Problema Real: Rendimiento Academico

Problema

¿Como podemos predecir y mejorar el rendimiento academico de los estudiantes de Ingenieria?

Motivacion:

- Alta retencion en materias
- **Identificar estudiantes en riesgo**
- Optimizar recursos educativos
- Prever tiempo de egreso
- Evaluar cambios curriculares

Contexto:

- 416 Materias
- 190,108 Matriculaciones (historico)
- **Nuevos datos:** 2024-2025
- 7 Carreras de Ingenieria
- Estudiantes de la FIUNA

Evolucion del Proyecto

CNMAC 2024 → Nuevos Datos → Mejores Modelos

Nuevos Datos: Estructura Actual

Fuentes de Datos

- Archivos Excel de rendimiento academico
- Período: 2024 - 2025 (muestra actual)
- 3 archivos concatenados
- Formato anonimizado

Estructura del Dataset

- **64,295** registros totales
- **4,759** estudiantes unicos
- **326** asignaturas unicas
- **30** columnas
- 7 carreras de Ingenieria

Mantiene la estructura del estudio CNMAC

Estructura de Columnas

Columna	Tipo	Descripcion
ALUMNO.ID	object	Identificador unico del estudiante
Cod.Asign	int64	Codigo de asignatura
Asignatura	object	Nombre de la asignatura
Cod.Car.Sec	object	Codigo de carrera-seccion
Cod.Curso	int64	Nivel de la materia
Convocatoria	int64	Numero de convocatoria
Año	int64	Año academico
Semestre	int64	Semestre (1 o 2)
Doc.Firma	int64	ID del docente
Aprobado	object	S/N (Si/No)
Primer.Par	int64	Nota primer parcial
Segundo.Par	int64	Nota segundo parcial
TPLab.	int64	Nota trabajos practicos/lab
Lab.	int64	Nota laboratorio
Proy.	int64	Nota proyecto
Firma	float64	Nota final

Proceso de Carga y Concatenacion

Estrategia de Carga

1. Identificar archivos de Excel en directorio
2. Leer cada archivo con pandas
3. Extraer año y semestre del nombre del archivo
4. Concatenar en un solo DataFrame
5. Agregar columna de origen

Resultado de la Carga

Archivo	Año	Registros
rendimiento_2024_ciclo_2	2024	24,468
rendimiento_2025_ciclo_1	2025	19,407
rendimiento_2025_ciclo_2	2025	20,420
Total		64,295

64,295 registros listos para analisis

PAUSA PRACTICA - A CODIFICAR

Cargar y explorar los datos academicos

Tareas

1. Cargar los archivos Excel usando pandas
2. Concatenar en un solo DataFrame
3. Mostrar estadísticas descriptivas
4. Identificar datos faltantes
5. Calcular tasa de aprobación general
6. Identificar top 5 asignaturas con menor aprobación

Preguntas para responder

- ¿Cuál es la tasa de aprobación en Física 3?
- ¿Qué carrera tiene mejor rendimiento en el ciclo básico?

Estadísticas Descriptivas Basicas

Variable	Media	Std	Min/Max
Cod.Asign	16,747.53	6,068.58	2,403 / 23,757
Cod.Curso	5.66	3.48	1 / 13
Convocatoria	1.31	0.46	1 / 2
Anho	2024.62	0.49	2024 / 2025
Semestre	1.70	0.46	1 / 2
Primer.Par	48.89	31.73	0 / 100
Segundo.Par	47.45	34.51	0 / 100
Lab.	24.86	41.66	0 / 100
Firma	50.72	32.99	-1 / 100

Grandes variaciones en las calificaciones

Columna	Faltantes	Porcentaje
FirmaCalculada	44,888	69.82 %
Nota.Final	21,575	33.56 %

Decision sobre datos faltantes

- **FirmaCalculada**: Se puede calcular a partir de las notas
- **Nota.Final**: Depende de aprobacion
- Se debe documentar claramente el tratamiento
- No eliminar datos si se pueden imputar

El tratamiento de datos faltantes es critico para el analisis

Estadisticas Globales

- **Aprobados (S):** 39,005 (60.67 %)
- **Reprobados (N):** 25,290 (39.33 %)

Tasa de Aprobacion por Año

Año	Reprobados	Aprobados
2024	40.47 %	59.53 %
2025	38.64 %	61.36 %

Mejora leve en la tasa de aprobacion entre 2024 y 2025

Top Asignaturas con mas Registros

Asignatura	Registros
CALCULO 1	1,907
ESTATICA	1,798
GEOMETRIA DESCRIPTIVA	1,670
MECANICA DE MATERIALES 1	1,646
ALGEBRA LINEAL	1,536
ELECTRICIDAD Y MAGNETISMO	1,515
PROBABILIDAD	1,457
MECANICA Y CALOR	1,390
PASANTIA	1,317
ECUACIONES DIFERENCIALES	1,245

Materias del ciclo basico dominan los registros

Distribucion por Carrera

Carrera	Registros
CIV	26,879
ELE	11,290
MCT	6,771
IND	6,045
CGF	4,538
MEC	2,340
INT9CONSTR	1,861
ECA	1,641
Otras	2,930

Civil lidera en numero de registros, seguido de Electronica y Mecatronica

Feature Engineering: Variables Clave

Variables Existentes (del CNMAC)

- Primer.Par, Segundo.Par, TPLab., Lab., Proy.
- Aprobado (S/N)
- Convocatoria (intento)
- Cod.Curso (nivel)
- Carrera

Variables a Crear

1. **FirmaCalculada** = $\sum(Pond_i \times Nota_i)$
2. **Intento** = Convocatoria (1er, 2do intento)
3. **Aprobo** = 1 si Aprobado == 'S' else 0
4. **TieneRequisito** = 1 si Requisito == 1
5. **PromedioParciales** = $(1P + 2P) / 2$

PAUSA PRACTICA - A CODIFICAR

Crear variables predictivas y preparar datos

Tareas

1. Calcular `FirmaCalculada` a partir de ponderaciones
2. Crear variable `Aprobo` (0/1)
3. Identificar estudiantes con `SegundoIntento`
4. Normalizar variables numericas (`StandardScaler`)
5. Codificar variables categoricas (`OneHotEncoder`)
6. Separar en `X` (features) e `y` (target)

Preguntas

- ¿Que variables consideras mas importantes para predecir aprobacion?
- ¿Como manejas la variable `Asignatura` (326 valores unicos)?
- ¿Que modelo usarias primero para predecir aprobacion?

Preprocesamiento: Limpieza de Datos

Pasos de Limpieza

1. **Valores Atipicos:** Identificar notas fuera de rango (0-100)
2. **Datos Faltantes:** Decidir imputacion o eliminacion
3. **Duplicados:** Eliminar registros duplicados
4. **Consistencia:** Unificar criterios de notas
5. **Codificacion:** Convertir variables categoricas

Comparacion con CNMAC

- Mismas variables, nuevos datos
- **Segundo Intento** sigue siendo clave
- Validar consistencia con datos historicos

?Por que normalizar?

- Las variables tienen escalas diferentes
- **Convocatoria** 1-2 vs **Notas** 0-100
- Sin normalizacion, el modelo da peso excesivo a ciertas variables
- **En el CNMAC:** la normalizacion mejoro los resultados

Tecnicas de Normalizacion

1. **Min-Max:** $x' = \frac{x - x_{min}}{x_{max} - x_{min}}$
2. **Z-score:** $x' = \frac{x - \mu}{\sigma}$
3. **Robust Scaler:** Usa mediana y percentiles

La normalizacion es obligatoria para la mayoría de los modelos

Codificación de Variables Categoricalas

Variables Categoricalas

- Aprobado (S/N) → **Target**
- Carrera → One-Hot
- Asignatura → Target Encoding
- Requisito (0/1) → Label
- Semestre → Label

Metodos de Codificacion

1. **Label Encoding:** Para variables ordinales
2. **One-Hot Encoding:** Para variables nominales (carrera)
3. **Target Encoding:** Para variables de alta cardinalidad (asignatura)

La eleccion de codificacion afecta el rendimiento del modelo

Modelos: Comparacion con CNMAC

Modelos del CNMAC

1. **Regresion Logistica**: Baseline (85.8 % Accuracy)
2. **MLP (Red Neuronal)**: 5 capas (88.3 % Accuracy)
3. Mejora del 2.5 % con MLP

Modelos a Probar con Nuevos Datos

1. **Regresion Logistica**: Validar consistencia
2. **MLP**: Ajustar arquitectura
3. **Random Forest**: Maneja interacciones
4. **XGBoost**: Estado del arte en tabular

Comparar resultados con el estudio original

Variables Mas Importantes (Validacion)

Variable	Coficiente
2nd Try (Segundo Intento)	6.59
Primer Parcial (1P)	1.98
Año	-2.49
Curso	0.10
Carrera	0.48

Conclusiones Esperadas

- **Segundo Intento** sigue siendo el predictor mas fuerte
- **Primer Parcial** permite deteccion temprana
- El modelo permite **intervencion temprana**
- Consistencia con resultados del CNMAC

Sistema de Alerta Temprana

- Identificar estudiantes en riesgo antes del examen final
- Basado en notas de 1P y 2P
- Intervencion temprana: tutorias, reforzamiento

Optimizacion Academica

- Identificar materias criticas (Ej: Mecanica de Materiales 1)
- Analizar impacto de cambios curriculares
- Asignacion optima de recursos
- Predecir tiempo de egreso

Del paper a la practica: impacto real en los estudiantes

Quiz Final

Quiz Rapido

?Que variable del estudio CNMAC resulto ser el mejor predictor de aprobacion?

1. Nota final (Firma)
2. Segundo Intento (2nd Try)
3. Convocatoria
4. Laboratorio

Quiz Rapido

?Cual fue la principal mejora del modelo MLP sobre la Regresion Logistica?

1. Redujo el overfitting
2. Mejoro Accuracy en 2.5 % y MCC en 0.045

Conclusiones

Lecciones Aprendidas

- El **preprocesamiento** es el paso mas critico
- La **EDA** guia las decisiones de modelado
- Las **escalas** afectan la interpretabilidad
- El **Feature Engineering** mejora los modelos
- Los modelos **MLP** superan a la regresion logistica
- Los resultados del CNMAC se **validan** con nuevos datos

Proximos Pasos

- Implementar modelos predictivos completos
- Desarrollar sistema de alerta temprana
- Integrar con sistema academico
- Publicar nuevos resultados

?Preguntas? Sobre el CNMAC, los nuevos datos, o el
preprocesamiento ¡Manos a la obra en el notebook!

Recuerden:
Preprocesar siempre antes de modelar