



UNIVERSIDAD NACIONAL DE ASUNCIÓN
FACULTAD DE
INGENIERÍA

Esquema de la presentación

- **Modelado del rendimiento académico: Un caso de estudio aplicado sobre estudiantes de Ingeniería**

Hans Rolan E. Mersch Fernandez¹, Carlos Sauer, Jose Rivas, Diego H. Stalder



Los Problemas: Alta retención en materias, Estudiantes

FIUNA analiza causas de retención en materias y diseña estrategias para una mayor eficiencia

Publicado por *Administrador* on julio 4th, 2014



La **Facultad de Ingeniería de la Universidad Nacional de Asunción (FIUNA)** realizó la primera reunión específica del **Comité de Análisis de Materias de Alta Retención (CAMAR)**. La primera materia sobre la cual se trabajó fue **Mecánica de Materiales 1**, con el objetivo de lograr un resultado más eficiente en cuanto al rendimiento de los alumnos en la mencionada materia.

Mecánica de Materiales 1, Química General, Probabilidad y Estadística, Hidráulica 1 y 2, Topografía.



- Optimizar rubros y secciones
- Prever tiempo de egreso
- Identificar estudiantes y materias con problemas
- Evaluar cambios de malla y reglamentos




UNIVERSIDAD NACIONAL DE ASUNCIÓN
FACULTAD DE
INGENIERÍA



Datos y Metodología

7 carreras

416 Materias





2012-2021, sin 2020

190108 Matriculaciones






Atributos





UNIVERSIDAD NACIONAL DE ASUNCIÓN
FACULTAD DE
INGENIERÍA


Atributos




Modelos

$$p(x) = \sigma(z) = \frac{1}{1 + e^{-z}}$$

$$z = \sum_{i=0}^p \theta_i x_i = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \dots + \theta_p x_p = \theta_0 + X^T \Theta$$



MLP 4 capas(10,20,10,10, 2)




TensorFlow

Entrenamiento



ADAM: Kingma et al., 2014

$$\begin{aligned}
 & \text{Indicator variable} \quad \text{Prob of class } j \\
 & - \sum_{j=1}^M y_j \log(p(y_j)) \\
 & \quad \uparrow \text{Sum over classes} \\
 & \text{Sum over trials} \quad \text{Label} \quad \text{Prob of positive class} \quad \text{Label} \quad \text{Prob of positive class} \\
 & - \sum_{i=1}^N y_i \log(p(y_i)) + (1 - y_i) \log(1 - p(y_i))
 \end{aligned}$$



Métricas

$$\text{Accuracy} = \frac{(TP + TN)}{(TP + FP + TN + FN)}$$

Matthews correlation coefficient **MCC**

A

		Predicted	
		Control	Disease
Actual	Control	TN	FP
	Disease	FN	TP

B

$$\text{MCC} = \frac{(TP \times TN) - (FP \times FN)}{\sqrt{(TP + FP)(TP + FN)(TN + FP)(TN + FN)}}$$



UNIVERSIDAD NACIONAL DE ASUNCIÓN
FACULTAD DE
INGENIERÍA

Resultados Regresion Logística

```
Index(['Asignatura Codificada', 'Cod.Car.Sec Codificado', '1P', '2P', 'Taller',  
      'Aprobado'],
```

```
coef_:
```

```
Coefficient of the features in the decision function.
```

```
[[ 0.38702827 -0.15976851  1.7033008   3.38703679  0.19342662]]
```

```
intercept_:
```

```
Intercept (a.k.a. bias) added to the decision function.
```

```
[-2.15216973]
```

```
n_features_in_:
```

```
Number of features seen during fit.
```

```
5
```

```
'Matriz de Confusion:'
```

```
[[11689  4747]
```

```
 [ 3082 18504]]
```

```
Exactitud del modelo:  79.40928935879228  %
```

```
Coefficiente de Matthews de la regresion logistica
```

```
0.5777185440746513
```



Resultados Regresión Logística

Model	θ_0	Course	Career	2nd Try	Year	1P	2P	L/W	ACC	MCC
1	-2.152	0.879	-0.160			1.703	3.387	0.193	79.4%	0.577
2	-1.207	0.348	-0.124		-2.221	1.759	3.487	0.289	79.7%	0.584
3	-6.153	0.387	0.020	6.119		0.902	1.721	1.721	85.1%	0.717
4	-5.322	0.437	0.093	6.520	-2.514	1.771		0.367	85.7%	0.723
5	-5.276	0.476	0.097	6.592	-2.494	1.976			85.8%	0.726



UNIVERSIDAD NACIONAL DE ASUNCIÓN
FACULTAD DE
INGENIERÍA

Resultados Redes Neuronales

```
Index(['Asignatura Codificada', 'Cod.Car.Sec Codificado', 'Recursante', 'Anho',  
      '1P', 'Aprobado'],
```

```
Epoch 00080: val_accuracy did not improve from 0.88441
```

```
Epoch 00080: early stopping
```

```
Saved model to disk
```

```
'Matriz de Confusion:'
```

```
[[12435  4001]
```

```
 [  426 21160]]
```

```
Exactitud del modelo MLP:  88.35674083425386  %
```

```
Coeficiente de Matthews de la MLP
```

```
0.7715314407641727
```

```
'Matriz de Confusion:'
```

RL

```
[[11404  5032]
```

```
 [  356 21230]]
```

```
Exactitud del modelo:  85.82925674609436  %
```

```
Coeficiente de Matthews de la regresion logistica
```

```
0.7259891357615023
```



UNIVERSIDAD NACIONAL DE ASUNCIÓN
FACULTAD DE
INGENIERÍA


Resultados Por Materia:

Entrada ["Taller", "1P"]

```
kfold = KFold(n_splits=10)
results = cross_val_score(logistic_regression, X_train, y_train, cv = kfold, scoring = 'accuracy')
print("10-fold cross-validation average accuracy : %.3f" % (results.mean()))
```

10-fold cross-validation average accuracy : 0.771

Estática
Estática



Estudiante Ing. MCT Caleb Trepowski

Dinámica

Entrada ["1P", "2P"]

Support Vector Machine (SVM)

-
Precisión: 77.18120805369128 %

Matriz de Confusión:

[[54 19]

[15 61]]


Precisión relativa entre ambos casos: 1.7699115044247764 %

Estudiante Ing. MCT Ricardo Romero




UNIVERSIDAD NACIONAL DE ASUNCIÓN
FACULTAD DE
INGENIERÍA

Resultados: Tiempo de Permanencia MCT



Los que ya pasaron






3.1 Años

Por Brenda Cruz, Estudiante de Ing. MCT

https://github.com/BrendaxCruz/1erParcial_IA


Trabajos futuros

- Los modelos nos ayudan a identificar variables importantes
- Tomar decisiones basadas en evidencias para optimizar recursos
- Planificar mejor el uso de los recursos






Trabajos futuros






Trabajos futuros





Trabajos futuros





Trabajos futuros

