

Semana 5 / Clase 5

Machine Learning 1

Clase 5: Regresión Logística, Optimización por Máxima Verosimilitud y Clasificación


Basado en Andrew Ng CS229 Cap.2

Universidad Nacional de Asunción

Facultad de Ingeniería *FIUNA*

Semestre Séptimo - Ingeniería Electrónica

El Problema de la Clasificación vs. Regresión Lineal



Comparativa: Vulnerabilidad de la Regresión Lineal ante Outliers *Izquierda* vs. Curva Sigmoide Logística Acotada $[0, 1]$ *Derecha*

Intuición: El Problema de la Clasificación Binaria

¿Por qué falla la Regresión Lineal en Clasificación?


- **Salidas No Acotadas:** Una recta $y = wx + b$ produce valores como -2.5 o $+3.8$, imposibles de interpretar como probabilidades.
- **Sensibilidad Severa a Outliers:** Un solo valor atípico lejano aplasta la pendiente de la recta, desplazando el umbral $y = 0.5$ y arruinando las predicciones.

La Solución: La Regresión Logística

En lugar de ajustar una recta continua, ajustamos una **curva suave en forma de "S"** *Sigmoide* que comprime cualquier valor real al rango probabilístico estricto $[0, 1]$.

La Función Sigmoide $g(z)$ y su Derivada

Función Sigmoide y su Derivada Fundamental (CS229 Cap. 2)



Curva Sigmoide $g(z) = \frac{1}{1 + e^{-z}}$ Azul y su Derivada Fundamental $g'(z) = g(z)(1 - g(z))$ Rojo Discontinuo

De la Entrada a la Probabilidad: La Función Sigmoid

Definición Matemática del Activador

Dado un puntaje z de combinación lineal $z = \theta^T x = \theta_0 + \theta_1 x_1 + \dots + \theta_n x_n$:

$$g(z) = \frac{1}{1 + e^{-z}}$$


Propiedades Clave y Derivada Fundamental

- **Punto Central:** Si $z = 0 \implies g(z) = 0.5$
Máxima incertidumbre.
- **Límites Estrictos:** Si $z \rightarrow +\infty \implies g(z) \rightarrow 1$. Si $z \rightarrow -\infty \implies g(z) \rightarrow 0$.
- **Derivada Elegante:**

$$g'(z) = g(z)(1 - g(z))$$

Variación del Umbral de Decisión Probabilístico τ

Conversión de Probabilidad Continuada $P(y = 1|x)$ a Decisión Discreta según Umbral τ



División del espacio probabilístico continuo en decisiones discretas $y=1$ vs $y=0$ según el umbral de corte τ

De Probabilidades a Decisiones Físicas: El Umbral τ

Regla de Decisión Discreta


El modelo devuelve una probabilidad continua $P(y = 1|x) \in [0, 1]$. Para tomar una decisión física *Aprobado* vs. *No Aprobado*, fijamos un **Umbral de Corte** τ :

$$\hat{y} = \begin{cases} 1 & \text{si } P(y = 1|x) \geq \tau \\ 0 & \text{si } P(y = 1|x) < \tau \end{cases}$$

Flexibilidad del Umbral según la Aplicación

- $\tau = 0.5$ *Estándar*: Balance neutro entre clases.
- $\tau = 0.3$ *Sensible/Conservador*: Prioriza detectar todos los casos positivos
ej. Detección temprana de fallas en ingeniería o diagnóstico médico.
- $\tau = 0.7$ *Estricto*: Exige alta certeza antes de clasificar como positivo.

Penalización de Costo Binary Cross-Entropy $BCELoss$



Curvas de Penalización Convexas: Costo cuando $y = 1$ *Izquierda* vs. Costo cuando $y = 0$ *Derecha*

¿Cómo Mide el Modelo sus Errores? *BCELoss*

¿Por qué no usar el Error Cuadrático Medio *MSE*?

En regresión logística, la combinación del MSE con la sigmoide produce una función de costo **no convexa** con múltiples mínimos locales donde el gradiente se atasca.

La Penalización Logarítmica Convexa

- Si la clase real es $y = 1$, el costo es $-\log(h_\theta(x))$. Si el modelo predice $h \rightarrow 0$, ¡la penalización tiende a $+\infty$!
- Si la clase real es $y = 0$, el costo es $-\log(1 - h_\theta(x))$. Si el modelo predice $h \rightarrow 1$, ¡la penalización tiende a $+\infty$!

Formulación Probabilística y Máxima Verosimilitud MLE

Modelo de Bernoulli Unificado

La probabilidad condicional para $y \in \{0, 1\}$ se escribe de forma compacta como:

$$p(y \mid x; \theta) = (h_\theta(x))^y (1 - h_\theta(x))^{1-y}$$

donde $h_\theta(x) = g(\theta^T x) = \frac{1}{1+e^{-\theta^T x}}$.

Función de Log-Verosimilitud y Costo

Para m muestras i.i.d., maximizamos la **Log-Verosimilitud** $l(\theta)$:

$$l(\theta) = \sum_{i=1}^m \left[y^{(i)} \log h_\theta(x^{(i)}) + (1 - y^{(i)}) \log(1 - h_\theta(x^{(i)})) \right]$$

Minimizar la costo $J(\theta) = -\frac{1}{m}l(\theta)$ equivale exactamente a la función de verosimilitud MLE.

Optimización: Descenso del Gradiente **Gradient Descent**

Derivada del Costo $J(\theta)$

Derivando $J(\theta)$ con respecto al parámetro θ_j :

$$\frac{\partial J(\theta)}{\partial \theta_j} = \frac{1}{m} \sum_{i=1}^m \left(h_{\theta}(x^{(i)}) - y^{(i)} \right) x_j^{(i)}$$

Expresión Matricial Vectorizada

$$\nabla_{\theta} J(\theta) = \frac{1}{m} X^T (h_{\theta}(X) - y)$$


Regla de actualización con tasa de aprendizaje $\alpha > 0$:

$$\theta := \theta - \alpha \nabla_{\theta} J(\theta)$$

Características Algorítmicas

- **Optimización de 1º Orden:** Utiliza únicamente derivadas primeras.
- **Complejidad por Iteración:** $\mathcal{O}(m \cdot n)$
vectorización rápida.
- **Escalabilidad:** Excelente para conjuntos de datos masivos
 $m \gg 100,000$.

Convergencia de Gradient Descent vs. Newton-Raphson



Comparación de Convergencia: Gradient Descent *Azul*, 300iters vs. Método de Newton-Raphson *Naranja*, $< 15iters$

Optimización: Método de Newton-Raphson *IRLS*

Optimización de Segundo Orden

Aprovecha la curvatura local mediante la **Matriz Hessiana** $H \in \mathbb{R}^{(n+1) \times (n+1)}$:

$$\theta := \theta - H^{-1} \nabla_{\theta} J(\theta)$$


Matriz Hessiana Vectorizada:

$$H = \frac{1}{m} X^T D X, \quad D_{ii} = h_{\theta}(x^{(i)})(1 - h_{\theta}(x^{(i)}))$$

Convergencia Cuadrática

Alcanza la solución óptima en muy pocas iteraciones **\$<15\$ iters**. Sin embargo, invertir H requiere $\mathcal{O}(n^3)$ operaciones de cálculo matricial.

Interpretación Didáctica de Odds Ratios $\exp(\theta_j)$



Factor de Multiplicación de las Opciones de Aprobación por cada incremento en los Atributos

Interpretación Didáctica: Coeficientes θ y Odds Ratios

¿Qué representan los Coeficientes θ_j ?

A diferencia de la regresión lineal, θ_j representa el cambio en el **Logit** *Log – Odds* por unidad de incremento en x_j :


$$\log \left(\frac{P(y = 1|x)}{1 - P(y = 1|x)} \right) = \theta_0 + \theta_1 x_1 + \dots + \theta_n x_n$$

Interpretación del Odds Ratio $\exp(\theta_j)$

$$\text{Odds Ratio} = e^{\theta_j}$$

- **Si $e^{\theta_j} > 1$:** Multiplica e incrementa las posibilidades de pertenecer a la clase positiva.
- **Si $e^{\theta_j} = 1$:** Sin efecto en la predicción.

Geometría de la Frontera de Decisión Lineal



Hiperplano de Decisión Lineal $\theta_0 + \theta_1 x_1 + \theta_2 x_2 = 0$ separando Clase 0 y Clase 1

Geometría de las Fronteras de Decisión Lineales

Geometría del Hiperplano de Decisión

La frontera de decisión representa la región del espacio donde el modelo está en máxima incertidumbre $P(y=1|x = 0.5)$:

$$h_{\theta}(x) = 0.5 \iff g(\theta^T x) = 0.5 \iff \theta^T x = 0$$

Ecuación del Hiperplano 2D

$$\theta_0 + \theta_1 x_1 + \theta_2 x_2 = 0 \implies x_2 = -\frac{\theta_1}{\theta_2} x_1 - \frac{\theta_0}{\theta_2}$$

El vector de parámetros $\theta = [\theta_1, \theta_2]^T$ es perpendicular *ortogonal* a la frontera de decisión.

Fronteras No Lineales mediante Expansión Polinomial

Mapeo a Espacios de Mayor Dimensión

Para conjuntos de datos no separables linealmente, mapeamos $x \in \mathbb{R}^n$ a un vector extendido $\phi(x) \in \mathbb{R}^d$ con términos polinomiales:


$$\phi(x) = [1, x_1, x_2, x_1^2, x_1x_2, x_2^2, x_1^3, \dots]$$

El modelo sigue siendo **lineal en los parámetros** θ , pero produce fronteras complejas en el espacio original.

Ejemplos de Geometrías No Lineales

- **Frontera Circular:** $\theta_0 + \theta_1x_1^2 + \theta_2x_2^2 = 0 \implies x_1^2 + x_2^2 = r^2$.
- **Frontera Elíptica:** $\theta_0 + \theta_1x_1^2 + \theta_2x_2^2 + \theta_3x_1x_2 = 0$.

Impacto de la Regularización L_2 $C = 1/\lambda$



Efecto del Parámetro C : Underfitting $C=0.01$ vs. Óptimo $C=1.0$ vs. Overfitting $C=100.0$

Regularización L_2 $C = 1/\lambda$ y Control de Overfitting

Función de Costo Regularizada


Penaliza la magnitud de los parámetros θ_j **excluyendo el bias θ_0** :

$$J_{reg}(\theta) = J(\theta) + \frac{\lambda}{2m} \sum_{j=1}^n \theta_j^2 = J(\theta) + \frac{1}{2mC} \sum_{j=1}^n \theta_j^2$$

Interpretación del Hiperparámetro C

- $C \rightarrow 0$ **$\lambda \rightarrow \infty$** : Regularización fuerte *evita el sobreajuste, fronteras suaves*.
- $C \rightarrow \infty$ **$\lambda \rightarrow 0$** : Sin regularización *fronteras sinuosas y riesgo de overfitting*.

Los Cuadrantes de la Matriz de Confusión



Estructura Didáctica de Verdaderos Positivos, Verdaderos Negativos, Falsos Positivos y Falsos Negativos

Evaluación Didáctica: Métricas de Clasificación

Los 4 Cuadrantes de Evaluación


- **Verdaderos Positivos** TP : Predicho Aprobado, Real Aprobado.
- **Verdaderos Negativos** TN : Predicho Reprobado, Real Reprobado.
- **Falsos Positivos** FP – *Error Tipo I*: Predicho Aprobado, Real Reprobado.
- **Falsos Negativos** FN – *Error Tipo II*: Predicho Reprobado, Real Aprobado.

Métricas Derivadas Fundamentales

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}, \quad \text{Precision} = \frac{TP}{TP + FP}$$

$$\text{Recall} = \frac{TP}{TP + FN}, \quad F_1\text{-Score} = 2 \frac{\text{Prec} \cdot \text{Rec}}{\text{Prec} + \text{Rec}}$$

Regiones de Decisión Multiclase Softmax *Dataset Iris*



Fronteras Multiclase $K=3$ generadas por la Función Softmax en el espacio 2D de Iris

Clasificación Multiclase: Regresión Softmax **\$K > 2\$**

La Función Softmax

Para $K > 2$ clases discontinuas $y \in \{1, \dots, K\}$, generalizamos la sigmoide a la función **Softmax**:

$$P(y = k \mid x; \Theta) = \frac{e^{\theta^{(k)T} x}}{\sum_{j=1}^K e^{\theta^{(j)T} x}}$$

Garantiza que la suma de probabilidades sobre las K clases sea exactamente 1.0.

Estrategia One-vs-Rest *OvR*

Entrena K clasificadores binarios independientes. Asigna la muestra a la clase con mayor probabilidad:

$$\hat{y} = \arg \max_{k \in \{1, \dots, K\}} h_{\theta^{(k)}}(x)$$

Conclusiones de la Clase 5

Curva Sigmoide & Umbral

Comprime cualquier entrada continua a una probabilidad en $[0, 1]$, permitiendo tomar decisiones mediante el umbral τ .

Optimización Convexa

La pérdida BCE elimina falsos mínimos.
Newton-Raphson logra convergencia cuadrática en pocos pasos con el Hessiano.

Regularización & Interpretación

El hiperparámetro $C = 1/\lambda$ controla el sobreajuste, mientras que los Odds Ratios e^{θ_j} cuantifican el impacto de cada variable.

¡Muchas Gracias!

