



Universidad Nacional de Asunción
Facultad de Ingeniería
Dirección Académica

PLAN DE CLASES SEGUNDO CICLO 2026

ASIGNATURA:	Machine Learning 1
CARRERA:	ELECTRONICA
SEMESTRE:	Séptimo
CODIGO:	23433
PROFESOR:	Dr. Diego Stalder
AUXILIAR DE PRAC- TICA:	Ing. Carlos Benitez
AUXILIAR DE LABO- RATORIO:	

INFORMACIÓN GENERAL

- **Inicio de Clases:** Lunes 20 de julio de 2026
- **Última Clase:** Lunes 2 de noviembre de 2026
- **Semanas de clase efectivas:** 14 semanas (con 2 semanas sin clase: 7 y 14 de septiembre)

Feriados y Días sin Clase

- **7 de septiembre (lunes): SIN CLASE** (Semana de exámenes - 1er Parcial)
- **14 de septiembre (lunes): SIN CLASE** (Semana de exámenes - 1er Parcial)
- **15 de agosto (sábado):** Fundación de Asunción (se traslada al lunes 17 de agosto) - **FERIADO**
- **28 de septiembre (lunes):** Victoria de Boquerón - **FERIADO**
- **2 de noviembre (lunes):** Última clase

Fechas de Exámenes

- **Primer Examen Parcial:** Semana 8 (7-14 de septiembre) - cuestionario + TP práctico
- **Segundo Examen Parcial:** Noviembre - GitHub Page del proyecto

Sistema de Evaluación

- **Cuestionarios:** evaluaciones breves agrupadas por semanas
- **TPs prácticos:** trabajos aplicados en repositorio de GitHub
- **Primer Parcial:** cuestionario + TP práctico (Semana 8)
- **Segundo Parcial:** GitHub Page con descripción del proyecto, objetivos y baseline
- **Proyecto de Curso:** desarrollo, presentación y defensa final

PLAN DE CLASES

Sem.	Fecha	CONTENIDO	Teo.	Prác.	Resp.
UNIDAD 1					
1	20/07	Teoría: Introducción al Machine Learning. Definición, conceptos básicos, historia, aplicaciones en ingeniería.	X		Diego Stalder
	20/07	Práctica: Configuración de entorno Python, Jupyter, Google Colab. Introducción a NumPy, Pandas y Matplotlib.		X	Carlos Benítez
2	27/07	Teoría: Tipos de Aprendizaje: Supervisado, No Supervisado y por Refuerzo. Ejemplos en ingeniería. Ética en ML.	X		Diego Stalder
	27/07	Práctica: Exploración de datasets famosos (Iris, MNIST, Boston Housing). Discusión ética de casos.		X	Carlos Benítez
UNIDAD 2					
3	03/08	Teoría: Preprocesamiento de Datos - Parte 1: Importancia, limpieza, manejo de valores faltantes, duplicados y ruido.	X		Diego Stalder
	03/08	Práctica: Limpieza de datos en dataset real (Titanic/House Prices). Imputación de valores faltantes.		X	Carlos Benítez
4	10/08	Teoría: Preprocesamiento de Datos - Parte 2: Transformación, normalización, estandarización, codificación de variables categóricas.	X		Diego Stalder
	10/08	Práctica: Pipeline de preprocesamiento completo. Selección de características.		X	Carlos Benítez
	17/08	FERIADO - Fundación de Asunción (traslado)			
UNIDAD 4					
5	24/08	Teoría: Regresión No Lineal: Limitaciones de la regresión lineal. Regresión polinómica, splines, KNN. Selección de modelos.	X		Diego Stalder
	24/08	Práctica: Regresión polinómica y splines. Comparación con regresión lineal. Análisis de overfitting.		X	Carlos Benítez
6	31/08	Teoría: Modelos Lineales, Sobreajuste y Regularización: regresión lineal, métricas, Bias-Variance Tradeoff, L1 (Lasso), L2 (Ridge), ElasticNet.	X		Diego Stalder
	31/08	Práctica: Comparación de modelos lineales y no lineales con/sin regularización. GridSearchCV para optimización.		X	Carlos Benítez
7	07/09	SIN CLASE - Semana de Estudio para 1er Examen Parcial			
8	14/09	PRIMER EXAMEN PARCIAL - Unidades 1, 2 y 4			
	14/09	Modalidad: Cuestionario + TP práctico			
UNIDAD 5					
9	21/09	Teoría: Máquinas de Soporte Vectorial (SVM) - Parte 1: Concepto de margen máximo, SVM lineal, optimización.	X		Diego Stalder
	21/09	Práctica: SVM lineal con scikit-learn. Visualización de vectores soporte y márgenes.		X	Carlos Benítez
10	28/09	Teoría: SVM - Parte 2: Kernel Trick (polinomial, RBF, sigmoide). SVR y aplicaciones. Hiperparámetros.	X		Diego Stalder
	28/09	Práctica: SVM con diferentes kernels. Comparación de rendimiento en dataset no lineal.		X	Carlos Benítez
	28/09	FERIADO - Victoria de Boquerón			
UNIDAD 6					

Sem.	Fecha	CONTENIDO	Teo.	Prác.	Resp.
11	05/10	Teoría: Reducción de la Dimensionalidad: PCA, LDA, t-SNE. Curse of dimensionality. Interpretación de componentes.	X		Diego Stalder
	05/10	Práctica: Implementación de PCA desde cero. Visualización de datos de alta dimensión. Comparación PCA vs t-SNE.		X	Carlos Benítez
UNIDAD 8					
12	12/10	Teoría: Árboles de Decisión: Construcción (CART, ID3), métricas (Gini, Entropía). Poda (Pruning). Interpretación.	X		Diego Stalder
	12/10	Práctica: Árboles de decisión. Feature importance. Implementación de poda para evitar overfitting.		X	Carlos Benítez
13	19/10	Teoría: Ensamble de Modelos: Bagging, Random Forest, Boosting (AdaBoost, Gradient Boosting, XGBoost). Algoritmo Apriori.	X		Diego Stalder
	19/10	Práctica: Comparación de ensambles: Random Forest, XGBoost, LightGBM. Optimización de hiperparámetros con Optuna.		X	Carlos Benítez
14	26/10	Tutoría del proyecto: documentación, objetivos, baseline y preparación de GitHub Pages.	X		Diego Stalder
	26/10	Tutoría del proyecto: publicación de avances y revisión del repositorio.		X	Carlos Benítez
15	02/11	Tutoría del proyecto: cierre de resultados y preparación de defensa final.	X		Diego Stalder
	02/11	Tutoría del proyecto: GitHub Pages y presentación final.		X	Carlos Benítez
	2do parcial	SEGUNDO EXAMEN PARCIAL: GitHub Page con descripción del proyecto, objetivos y baseline.	X	X	Diego Stalder - Carlos Benítez

Plan de clases completo

TPs y Cuestionarios

Semanas	Cuestionario	Trabajo Práctico
1-2	Cuestionario 1	TP1: Mi primer repo de GitHub + repositorio para todos los TPs
3-6	Cuestionario 2	TP2: Comparación de modelos de regresión lineal y no lineal + impacto de la regularización
7-8	Receso por evaluaciones	
9-10	Cuestionario 3	TP3: Ejemplo de clusterización con SVM
11	Cuestionario 4	TP4: Ejemplo de comparación de similitud de imágenes con PCA
12-13	Cuestionario 6	TP5: Optuna con comparación de modelos de decisión
14-15	Tutoria de proyecto	TP6: GitHub Pages

Cuadro 2: Evaluaciones por semana propuesta

1. Sistema de Evaluación Detallado

1.1. Componentes de Evaluación

Componente	Frecuencia	Ponderación
Cuestionarios	Según tabla de TPs y cuestionarios	10 %
TPs prácticos	TP1–TP6	10 %
Primer Examen Parcial	Cuestionario + TP	30 %
Segundo Examen Parcial	GitHub Page: descripción del proyecto, objetivos y baseline	20 %
Proyecto de Curso	Desarrollo, presentación y defensa final	30 %
TOTAL		100 %

Cuadro 3: Componentes de Evaluación

1.2. Exoneración

Los estudiantes que cumplan con los siguientes requisitos podrán acceder a la exoneración:

1. Haber completado el **100 %** de los TPs y cuestionarios
2. Haber presentado satisfactoriamente el proyecto final (defensa, informe y GitHub Page)

2. Proyecto de Curso

2.1. Descripción General

Desarrollo de un pipeline completo de Machine Learning para resolver un problema real de ingeniería, desde la adquisición de datos hasta el despliegue de un modelo predictivo.

2.2. Temáticas Sugeridas

- Predicción de demanda energética (series temporales)
- Clasificación de fallas en equipos industriales (mantenimiento predictivo)
- Segmentación de clientes para marketing (unsupervised)
- Predicción de precios de propiedades (regresión)
- Detección de fraudes en transacciones (clasificación desbalanceada)
- Optimización de procesos de manufactura (regresión/multiclase)
- Análisis de sentimiento en redes sociales (NLP básico)
- Predicción de calidad en procesos industriales

2.3. Estructura de Entregables

2.3.1. Primera Entrega (14 de septiembre)

- **GitHub Page:** descripción del proyecto y objetivos
- **Análisis Exploratorio de Datos (EDA):** estadísticas descriptivas, visualizaciones e identificación de problemas de calidad

- **Modelo Baseline:** modelo inicial con evaluación
- **Documentación:** avance publicado en repositorio y GitHub Pages

2.3.2. Entrega Final (2 de noviembre)

- **Modelos Avanzados:** SVM, Random Forest, XGBoost (3+ algoritmos)
- **Feature Engineering Avanzado:** Selección, reducción de dimensionalidad
- **Análisis de Resultados:** Tablas comparativas, interpretación (SHAP, feature importance)
- **Dashboard:** Visualización interactiva (Streamlit/Dash)
- **Modelo Final:** Modelo optimizado y validado
- **Presentación:** Slides tipo pitch técnico (10-15 slides)
- **API:** Endpoint para predicciones (FastAPI/Flask)

2.4. Estructura de GitHub

```
/proyecto-ml/  
  /notebooks/  
    01_EDA.ipynb  
    02_preprocessing.ipynb  
    03_baseline_model.ipynb  
    04_advanced_models.ipynb  
    05_feature_engineering.ipynb  
    06_model_comparison.ipynb  
  /data/  
    /raw/  
    /processed/  
  /models/  
    best_model.pkl  
    hyperparameters.json  
  /api/  
    app.py (FastAPI/Flask)  
    Dockerfile  
  /dashboard/  
    app.py (Streamlit)  
  /docs/ (GitHub Pages)  
  /reports/  
    informe_parcial1.pdf  
    informe_final.pdf  
  /presentation/  
    slides.pdf  
  README.md  
  requirements.txt  
  .gitignore
```

2.5. GitHub Pages

- Página de inicio con descripción del proyecto
- Documentación técnica del modelo
- Demo interactiva
- Métricas y resultados
- Enlaces a notebooks y código

3. Actividades Plus

3.1. Seminario Invitado

Fecha sugerida: Semana 10 (28 de septiembre) - previo al feriado

Título: “Machine Learning en la Industria Paraguaya: Experiencias y Desafíos” **Formato:** 2 horas (1.5h presentación + 0.5h Q&A)

3.2. Competencia Internacional o Shell lab(de FIUNA)

Modalidad: Participación en competencia regionales o nacionales.

4. Bibliografía

4.1. Bibliografía Básica

1. Murphy, Kevin P. *Machine learning: a probabilistic perspective*. MIT press, 2012.
2. Hastie, Trevor, et al. *The elements of statistical learning: data mining, inference, and prediction*. Vol. 2. New York: springer, 2009.
3. Alpaydin, Ethem. *Introduction to machine learning*. MIT press, 2020.
4. Géron, Aurélien. *Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow*. O'Reilly Media, Inc., 2022.
5. Müller, Andreas C., and Sarah Guido. *Introduction to machine learning with Python: a guide for data scientists*. O'Reilly Media, Inc., 2016.
6. James, Gareth, et al. *An introduction to statistical learning*. Vol. 112. New York: springer, 2013.

4.2. Bibliografía Complementaria

7. Ng, Andrew. *Machine learning yearning*. URL: <http://www.mlyearning.org/>
8. Goodfellow, Ian, Yoshua Bengio, and Aaron Courville. *Deep learning*. MIT press, 2016.
9. Kelleher, John D., Brian Mac Namee, and Aoife D'arcy. *Fundamentals of machine learning for predictive data analytics*. MIT press, 2020.
10. Burkov, Andriy. *The hundred-page machine learning book*. Vol. 1. Andriy Burkov, 2019.

5. Herramientas y Recursos

5.1. Software

- **Python:** 3.8+
- **Data:** pandas, numpy, scipy
- **Visualización:** matplotlib, seaborn, plotly
- **ML:** scikit-learn, xgboost, lightgbm, catboost
- **Deep Learning (opcional):** tensorflow/keras, pytorch
- **Despliegue:** streamlit, fastapi, docker
- **Versionado:** git, github

5.2. Recursos Adicionales

- Google Colab: <https://colab.research.google.com>
- Kaggle: <https://www.kaggle.com>
- Scikit-learn Documentation: <https://scikit-learn.org>
- Machine Learning Mastery: <https://machinelearningmastery.com>
- Towards Data Science (Medium): <https://towardsdatascience.com>
- Aula Virtual de la Facultad